

PREDIKSI PERGERAKAN HARGA BITCOIN-USDT MENGGUNAKAN BIDIRECTIONAL LONG SHORT-TERM MEMORY DALAM ANALISIS MULTIVARIATE TIME SERIES FORECASTING

Bryan Herdianto, Jesaya David Gamalael Nickhelsen Panggabean, Wesley Frederick Oh

Departemen Teknik Elektro, Fakultas Teknik, Universitas Indonesia

Kampus UI Depok, Jawa Barat, 16424, Indonesia

Penulis korespondensi: bryan.herdianto@ui.ac.id

Abstrak—Prediksi pergerakan harga aset kripto berfrekuensi tinggi menghadapi tantangan volatilitas ekstrem dan sifat pasar yang non-linier. Alih-alih memprediksi harga nominal yang non-stasioner, penelitian ini mengusulkan model *Multivariate Time Series Forecasting* berbasis *Bidirectional Long Short-Term Memory* (BiLSTM) untuk memprediksi *log-returns* 1 menit ke depan dan merekonstruksi harga penutupan Bitcoin-USDT dari *observation window* 120 menit. Menggunakan 135.266 data 1 menit dari bursa Binance (Q1 2024) dengan partisi kronologis ketat (70% *training*, 15% *validation*, 15% *testing*), model BiLSTM menghasilkan R^2 sebesar 0,9979, RMSE sebesar 76,80 USDT, dan MAE sebesar 61,45 USDT (*relative error* sekitar 0,08% pada level harga sekitar 69.000 USDT) pada 20.170 data *testing*. Yang terpenting, model mencapai *Directional Accuracy* sebesar 51,32% yang terbukti signifikan secara statistik ($Z=3,75$, $p\text{-value} < 0,0002$) dalam mengungguli *random baseline* 50,00%. Hasil ini membuktikan efektivitas pemodelan *sequence* dua arah dalam mengekstraksi sinyal prediktif pasar kripto.

Kata kunci: Bitcoin-USDT, *Bidirectional LSTM*, *Multivariate Time Series Forecasting*, *Directional Accuracy*, *Log>Returns*, *Deep Learning*.

I. PENDAHULUAN

Sejak diperkenalkannya protokol Bitcoin oleh Satoshi Nakamoto pada tahun 2008, pasar *cryptocurrency* telah berkembang secara eksponensial menjadi salah satu kelas aset finansial paling dinamis di dunia dengan kapitalisasi pasar melampaui 1,4 triliun dolar AS pada awal tahun 2024 [1]. Berbeda dengan pasar ekuitas konvensional yang memiliki jam operasional terbatas dan *circuit breaker*, pasar *cryptocurrency* beroperasi tanpa henti selama 24 jam setiap hari dalam ekosistem desentralisasi global. Karakteristik perdagangan terdesentralisasi ini memicu dinamika harga yang sangat *volatile*, didorong oleh interaksi kompleks antara volume transaksi, sentimen komunitas, adopsi token aktif, serta regulasi pemerintah di berbagai belahan dunia [2], [3].

Tingginya volatilitas harga aset kripto menciptakan ketidakpastian finansial yang signifikan bagi para pelaku pasar. Studi empiris mengenai perilaku investor kripto menunjukkan bahwa banyak pengguna mengalami risiko kerugian modal yang lebih tinggi dibandingkan investasi pada pasar saham tradisional jika hanya mengandalkan intuisi atau analisis teknikal manual [4], [5]. Oleh karena itu, perancangan model komputasi cerdas yang mampu memodelkan, memproyeksikan, dan mengantisipasi pergerakan harga jangka pendek secara akurat menjadi instrumen esensial dalam strategi mitigasi risiko portofolio dan pengambilan keputusan investasi kuantitatif.

Dalam domain *financial time series forecasting*, metode ekonometrika linier seperti *Autoregressive Integrated Moving Average* (ARIMA) dan model volatilitas GARCH kerap kali menghadapi kendala dalam menangkap sifat non-linier, *long-range memory*, serta lonjakan varians ekstrem pada data aset kripto [6]. Perkembangan pesat dalam bidang *machine learning* dan

deep learning membuka paradigma baru melalui *Recurrent Neural Network* (RNN). Varian *Long Short-Term Memory* (LSTM) yang diperkenalkan oleh Hochreiter dan Schmidhuber [7] dirancang untuk mengatasi masalah *vanishing gradient* melalui *gating mechanism*, memungkinkan jaringan menyimpan dependensi temporal dalam *sequence* panjang [8], [9].

Beberapa penelitian terdahulu telah mengkaji efektivitas model LSTM untuk peramalan harga aset finansial dan kripto, seperti studi oleh Pham Nam Hai et al. [10] pada pasar saham serta Sujjada et al. [11] pada harga Bitcoin. Namun, sebagian besar penelitian masih bertumpu pada LSTM konvensional *unidirectional*. LSTM *unidirectional* hanya mengolah representasi temporal masa lalu menuju masa depan, sehingga berpotensi melewatkan keterkaitan konteks struktural dalam *observation window* historis tertentu. Untuk mengatasi keterbatasan ini, penelitian ini mengusulkan penerapan *Bidirectional Long Short-Term Memory* (BiLSTM) [12] dalam kerangka *multivariate time series forecasting*.

Penelitian ini dibatasi pada peramalan kuantitatif pergerakan harga spot Bitcoin terhadap Tether (BTC-USDT) berfrekuensi tinggi (interval 1 menit) berbasis data teknikal internal bursa (OHLCV). Penelitian ini memfokuskan investigasi pada pemodelan *time series* tanpa mengintegrasikan data eksternal seperti sentimen media sosial, *order book depth*, atau variabel makroekonomi eksternal.

II. METODOLOGI PENELITIAN

A. Deskripsi Dataset dan Eksplorasi Fitur

Dataset yang digunakan dalam penelitian ini merupakan data pasar spot Bitcoin terhadap Tether (BTC-USDT) berfrekuensi satu menit yang diperoleh dari bursa Binance melalui repositori CryptoDataDownload. Rentang waktu

dataset mencakup periode 1 Januari 2024 pukul 00:01 hingga 7 April 2024 pukul 23:59, menghasilkan total 135.266 baris observasi temporal.


Pada bentuk mentahnya, dataset memuat variabel standar pasar finansial berupa *Open*, *High*, *Low*, *Close*, *Volume BTC*, dan *Volume USDT*. Dalam konteks analisis teknikal kuantitatif, rentang antara *High* dan *Low* mencerminkan volatilitas *intraday* pada menit terkait, sedangkan kedekatan antara *Open* dan *Close* merepresentasikan kekuatan tekanan beli atau jual.

Untuk memperkaya representasi pola temporal dan mengatasi isu non-stasioneritas pada level harga nominal, dilakukan *feature engineering* multivariat dengan menambahkan variabel diferensial *close_change* (ΔP_t) serta *log-returns* (r_t):

$$\Delta P_t = P_t - P_{t-1} \quad (1)$$

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) \quad (2)$$

Komponen waktu diekstraksi menjadi fitur kalender siklikal yang mencakup *day_of_week*, *day_of_month*, *week_of_year*, dan *month*, menghasilkan total 10 variabel prediktor multivariat. Visualisasi pergerakan harga penutupan Bitcoin-USDT sepanjang periode dataset disajikan pada Gambar 1.



Gambar 1. Visualisasi pergerakan harga penutupan BTC-USDT periode Januari — April 2024.

B. Preprocessing dan Partisi Data Kronologis

Tahap *preprocessing* data diawali dengan penyortiran urutan waktu secara tegas *ascending chronological order*. Hal ini penting untuk mencegah *look-ahead bias* atau *time-travel bug* yang kerap terjadi apabila dataset mentah berformat *descending* langsung diproses tanpa pengurutan ulang.

Selanjutnya, dilakukan penanganan *missing values*. Untuk memastikan proses *training neural network* konvergen secara efisien tanpa didominasi oleh variabel dengan skala numerik besar, seluruh fitur diskalakan menggunakan *Min-Max Scaling* ke dalam interval $[-1, 1]$:

$$x_{scaled} = \frac{2(x - x_{min})}{x_{max} - x_{min}} - 1 \quad (3)$$

Parameter nilai skala (x_{min} dan x_{max}) dihitung hanya menggunakan subset *training set*, kemudian diterapkan pada *validation set* dan *test set* untuk mencegah terjadinya *data leakage* ke dalam proses *training*.

Dataset dipartisi secara *chronological split* tanpa pengacakan (*shuffle=False*) menjadi tiga bagian: 1)

Training set sebesar 70% (94.686 sampel, 1 Jan – 10 Mar 2024) untuk pembaruan bobot model; 2) *Validation set* sebesar 15% (20.290 sampel, 10 Mar – 24 Mar 2024) untuk pemantauan regularisasi dan *early stopping*; dan 3) *Test set* sebesar 15% (20.290 sampel, 24 Mar – 7 Apr 2024) murni sebagai evaluasi akhir performa generalisasi model.

Pembentukan sampel masukan dilakukan menggunakan teknik *sliding window* dengan panjang *sequence* (W) adalah 120 menit. Model memanfaatkan runtutan informasi selama 2 jam sebelumnya [$X_{t-W+1}, \dots, X_t$] untuk memprediksi *log-returns* pada menit berikutnya ($Y_{t+1} = r_{t+1}$), yang kemudian direkonstruksi menjadi estimasi harga penutupan nominal.

C. Arsitektur Bidirectional LSTM dan Rekonstruksi Harga

Unit sel LSTM konvensional mengendalikan aliran informasi temporal melalui tiga *gate* utama: *forget gate* (f_t), *input gate* (i_t), dan *output gate* (o_t) [7]. Formulasi matematis dari *gating mechanism* pada langkah waktu t didefinisikan sebagai berikut:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (4)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (5)$$


$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (6)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (7)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (8)$$

$$h_t = o_t \odot \tanh(C_t) \quad (9)$$

di mana σ mewakili fungsi aktivasi sigmoid, $\odot$ merepresentasikan *Hadamard product*, W adalah matriks bobot transformasi, b adalah vektor bias, $x_t \in R^d$ merupakan vektor *input feature* pada menit ke- t , C_t adalah *cell state*, dan h_t adalah *hidden state*.



Gambar 2. Diagram arsitektur Bidirectional Long Short-Term Memory (BiLSTM).

Pada arsitektur *Bidirectional LSTM* (BiLSTM) [12] seperti diilustrasikan pada Gambar 2, proses pemodelan *sequence* diperluas dengan menggabungkan dua *layer* LSTM paralel: *forward layer* yang mengolah *sequence* dari $t = 1$ menuju W , dan *backward layer* yang memproses *sequence* dari $t = W$ menuju 1:

$$\vec{h}_t = LSTM_{forward}(x_t, \vec{h}_{t-1}) \quad (10)$$

$$\bar{h}_t = LSTM_{backward}(x_t, \bar{h}_{t+1}) \quad (11)$$

Hidden state akhir pada setiap langkah waktu dibentuk melalui konkatenasi vektor representasi dari kedua arah:

$$h_t^{Bi} = [\vec{h}_t \parallel \vec{h}_t] \in R^{2 \cdot n_{hidden}} \quad (12)$$

Vektor *hidden state* pada langkah waktu terakhir (h_W^{Bi}) diproyeksikan melalui *linear layer* untuk menghasilkan estimasi skalar *log-returns* $\hat{r}_{t+1}$:

$$\hat{r}_{t+1} = W_d \cdot h_W^{Bi} + b_d \quad (13)$$

Selanjutnya, proyeksi harga penutupan nominal $\hat{P}_{t+1}$ direkonstruksi menggunakan harga jangka riil terakhir P_t yang teramati di akhir jendela observasi:

$$\hat{P}_{t+1} = P_t \cdot \exp(\hat{r}_{t+1}) \quad (14)$$

Formulasi rekonstruksi ini menjamin bahwa estimasi harga selalu berlabuh pada level harga pasar terkini tanpa mengalami *level drift* atau saturasi numerik.

D. Optimasi Hyperparameter dan Protokol Training

Model diimplementasikan menggunakan *framework* PyTorch Lightning. Untuk menemukan konfigurasi parameter jaringan yang optimal secara empiris, diterapkan optimasi *hyperparameter* sistematis berbasis algoritma *Bayesian Optimization* menggunakan *library* Optuna [13]. Ruang pencarian parameter mencakup variasi panjang *sequence* $W \in \{30, 60, 120\}$ menit, kapasitas dimensi *hidden state* $n_{hidden} \in \{32, 64, 128\}$ unit, serta *learning rate* $\eta \in [10^{-4}, 10^{-3}]$.

Loss function yang dioptimalkan adalah *Mean Squared Error* (MSE) terhadap target *log-returns*:

$$L_{MSE} = \frac{1}{B} \sum_{b=1}^B (r_b - \hat{r}_b)^2 \quad (15)$$

Optimasi parameter dilakukan menggunakan algoritma Adam [14] dengan *learning rate* $\eta = 0,0005$. Untuk mencegah terjadinya fenomena *overfitting*, diterapkan mekanisme *callbacks* berupa *Early Stopping* dengan *patience* sebesar 2 *epoch* yang memantau nilai *validation loss* (val_{loss}). *Checkpoint* bobot model terbaik disimpan secara otomatis pada *epoch* yang menghasilkan *validation loss* terendah.

E. Metrik Evaluasi Kinerja dan Baseline Model

Untuk mengevaluasi performa prediksi secara objektif setelah dilakukan *downscaling* dan rekonstruksi harga ke satuan asli (USDT), digunakan empat metrik evaluasi kuantitatif standar [15]:

$$R^2 = 1 - \frac{\sum_{k=1}^N (y_k - \hat{y}_k)^2}{\sum_{k=1}^N (y_k - \bar{y})^2} \quad (16)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{k=1}^N (y_k - \hat{y}_k)^2} \quad (17)$$

$$MAE = \frac{1}{N} \sum_{k=1}^N |y_k - \hat{y}_k| \quad (18)$$

$$DA = \frac{1}{N} \sum_{k=1}^N \mathbb{I}(\text{sgn}(\hat{r}_k) = \text{sgn}(r_k)) \times 100\% \quad (19)$$

di mana y_k adalah harga penutupan aktual, $\hat{y}_k$ adalah harga prediksi terekonstruksi, r_k adalah imbal hasil aktual, $\hat{r}_k$ adalah *returns* prediksi, $\bar{y}$ adalah rata-rata harga aktual, dan DA merepresentasikan *Directional Accuracy*, yaitu persentase ketepatan prediksi arah pergerakan pasar (naik/turun). Sebagai *baseline* pembandingan, terdapat juga implementasi *Naïve Persistence Baseline*:

$$\hat{y}_{t+1}^{(Naïve)} = y_t, \quad \hat{r}_{t+1}^{(Naïve)} = 0 \quad (20)$$

Model *Naïve* merepresentasikan hipotesis *random walk / martingale* di mana ekspektasi *returns* adalah nol sehingga harga menit berikutnya diasumsikan persis sama dengan harga menit ini (DA teoritis = 50,00%).

III. HASIL DAN PEMBAHASAN

A. Hasil Evaluasi Kuantitatif dan Analisis Directional Accuracy

Setelah melalui proses *training* secara penuh dengan pemantauan validasi, model dievaluasi pada 20.170 sampel *sequence* data *testing* independen (pada periode 24 Maret – 7 April 2024). Ringkasan hasil evaluasi kuantitatif disajikan pada Tabel I.

Tabel I. Perbandingan Metrik Performa Model Prediksi Harga Bitcoin-USDT

Model	R ²	RMSE (USDT)	MAE (USDT)	Directional Accuracy
Naïve Persistence Baseline	0,9992	47,64	32,10	50,00%
BiLSTM Multivariat	0,9979	76,80	61,45	51,32%

Berdasarkan Tabel I, model BiLSTM multivariat mencatat nilai Koefisien Determinasi R^2 sebesar 0,9979 pada harga terekonstruksi, dengan RMSE sebesar 76,80 USDT dan MAE sebesar 61,45 USDT. Mengingat harga rata-rata Bitcoin pada *test set* berada di kisaran 69.000 USDT, nilai deviasi absolut 61,45 USDT mencerminkan *relative error* yang sangat kecil, yaitu hanya sekitar 0,08%.

Pencapaian paling esensial dalam penelitian ini terletak pada metrik *Directional Accuracy*. Dalam domain perdagangan kuantitatif berfrekuensi tinggi, memprediksi arah pergerakan harga (apakah harga naik atau turun pada menit berikutnya) jauh lebih penting daripada sekadar meminimalkan *nominal error*. Model *Naïve Persistence* tidak memberikan sinyal arah aktif (bersifat pasif, setara dengan probabilitas acak 50,00%). Sebaliknya, model BiLSTM berhasil mencapai *Directional Accuracy* sebesar 51,32% pada 20.170 sampel *test set*.


Secara inferensial, pada ukuran sampel *testing* $N = 20.170$, nilai 51,32% menghasilkan *Z-score* pengujian hipotesis binomial:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{N}}} = \frac{0,5132 - 0,5000}{0,00352} \approx 3,75 \quad (21)$$

Nilai $Z = 3,75$ menghasilkan $p\text{-value} < 0,0002$, yang secara tegas menolak *Random Walk Hypothesis* pada tingkat kepercayaan 99,9%. Hasil ini membuktikan bahwa BiLSTM mampu mengekstraksi sinyal prediktif nyata *alpha edge* dari pola *sequence* multivariat 120 menit sebelumnya.

B. Analisis Visualisasi Rekonstruksi Harga

Gambar 3 menyajikan perbandingan kurva antara harga aktual Bitcoin-USDT (garis biru) dengan proyeksi harga hasil rekonstruksi model BiLSTM (garis merah) sepanjang periode *testing* independen (25 Maret – 7 April 2024).




Gambar 3. Komparasi pergerakan harga aktual Bitcoin-USDT (biru) vs hasil proyeksi terekonstruksi model BiLSTM (merah).

Inspeksi visual pada Gambar 3 menunjukkan bahwa kurva prediksi model BiLSTM (garis merah) berhasil melacak dinamika pergerakan harga pasar secara sangat presisi di seluruh fase pasar, termasuk pada puncak reli harga (sekitar 71.500 USDT pada 27 Maret) dan saat terjadi koreksi tajam (sekitar 65.000 USDT pada 2 April). Fenomena garis horizontal mendatar atau *level drift* yang umum terjadi pada regresi harga mentah telah tereliminasi sepenuhnya berkat pemodelan *log-returns* yang berbasis jangka harga riil.

C. Dinamika Konvergensi Training dan Early Stopping

Gambar 4 menyajikan kurva dinamika *training loss* dan *validation loss* model BiLSTM yang dicatat secara kontinu melalui TensorBoard sepanjang langkah iterasi *training*.



Gambar 4. Kurva dinamika *training loss* (garis gelap) dan *validation loss* (garis biru) model BiLSTM.

Berdasarkan Gambar 4, kurva *training loss* (garis gelap) mengalami penurunan tajam dari fase awal dan mencapai titik konvergensi terendah pada kisaran langkah ke-4.500. Sementara itu, kurva *validation loss* (garis biru muda) menurun secara bertahap hingga menyentuh titik minimum global pada langkah ke-5.900 hingga 6.000.

Setelah melampaui langkah ke-6.000, kurva *validation loss* mulai menunjukkan *uptick*, yang merupakan indikator klasik munculnya fase *overfitting* saat *neural network* mulai menghafal *noise* lokal dari *training data*. Mekanisme *Early Stopping* dengan *patience* sebesar 2 *epoch* secara otomatis mendeteksi kenaikan ini dan menghentikan proses *training* pada langkah optimal tersebut. *Checkpoint* model terbaik yang meminimalkan *validation loss* diekstraksi untuk evaluasi pada *test set*, membuktikan efektivitas regulasi dalam menjamin kapasitas generalisasi model.

IV. KESIMPULAN DAN SARAN

Penelitian ini telah berhasil mengembangkan dan mengevaluasi kerangka kerja *Multivariate Time Series Forecasting* berbasis *Bidirectional Long Short-Term Memory* (BiLSTM) untuk memprediksi pergerakan aset kripto Bitcoin-USDT pada frekuensi data satu menit. Berdasarkan pengujian empiris pada 20.170 sampel *test set* independen, model BiLSTM membuktikan keunggulan prediktif dengan mencapai *Directional Accuracy* sebesar 51,32% ($Z\text{-score} = 3,75$, $p\text{-value} < 0,0002$) yang secara signifikan mengungguli *random baseline* 50,00%, serta merekonstruksi harga pasar dengan $R^2 = 0,9979$, RMSE = 76,80 USDT, dan MAE = 61,45 USDT. Penerapan pemodelan *log-returns* terbukti krusial dalam mengatasi kendala non-stasioneritas harga mentah, sementara mekanisme *Early Stopping* berhasil mengamankan model dari ancaman *overfitting*.

Untuk pengembangan penelitian selanjutnya, disarankan: 1) Mengintegrasikan data eksternal seperti analisis sentimen pasar dari media sosial secara *multimodal* serta *order book depth* guna menangkap dinamika likuiditas dan psikologi pasar secara lebih komprehensif; 2) Mengintegrasikan mekanisme *temporal attention* atau arsitektur *Transformer* untuk memberikan bobot dinamis pada langkah-langkah waktu kritis dalam *observation window*; serta 3) Mengembangkan strategi eksekusi perdagangan algoritmik otomatis berbasis sinyal prediksi BiLSTM yang telah tervalidasi.

DAFTAR PUSTAKA

- [1] L. Ledesma, "Bitcoin's market cap jumps to \$1.4T, surpassing silver," CoinDesk, Mar. 11, 2024. [Online]. Available: <https://www.coindesk.com>
- [2] Y. Sovbetov, "Factors influencing cryptocurrency prices: Evidence from Bitcoin, Ethereum, Dash, Litecoin, and Monero," J. Econ. Financ. Anal., vol. 2, no. 2, pp. 1–27, 2018.
- [3] S. Nakamoto, "Bitcoin: A peer-to-peer electronic cash system," Decentralized Business Review, 2008. [Online]. Available: <https://bitcoin.org/bitcoin.pdf>
- [4] J. Bhattacharjee, L. Pandey, R. Singh, and H. K. Baker, "Factors affecting the risk perceptions of cryptocurrency investors," J. Behav. Finance, pp. 1–13, 2024, doi: 10.1080/15427560.2024.2331474.
- [5] P. Jaquart, S. Köpke, and C. Weinhardt, "Machine learning for cryptocurrency market prediction and trading," J. Finance Data Sci., vol. 8, pp. 331–352, 2022, doi: 10.1016/j.jfds.2022.12.001.
- [6] M. Elsaraiti and A. Merabet, "A comparative analysis of the ARIMA and LSTM predictive models and their effectiveness for predicting wind speed," Energies, vol. 14, no. 20, p. 6782, 2021, doi: 10.3390/en14206782.

- [7] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [8] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [9] S. McNally, J. Roche, and S. Caton, "Predicting the price of Bitcoin using machine learning," in *Proc. 26th Euromicro Int. Conf. Parallel, Distrib. Netw.-Based Process. (PDP)*, 2018, pp. 339–343, doi: 10.1109/PDP2018.2018.00060.
- [10] P. N. Hai, N. T. K. Ngan, and N. T. B. Tram, "An empirical research on the effectiveness of different LSTM architectures on the Vietnamese stock market," in *Proc. 7th Int. Conf. Adv. Inform. Commun. Technol. (ICAICT)*, 2020, pp. 78–84, doi: 10.1145/3437802.3437827.
- [11] T. Sujjada, M. R. A. Pratama, and R. Noviana, "Prediksi harga Bitcoin menggunakan Long Short-Term Memory (LSTM) berbasis Python," *J. Teknol. Inf. dan Ilmu Komput. (JTIK)*, vol. 11, no. 2, pp. 345–354, 2024.
- [12] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Trans. Signal Process.*, vol. 45, no. 11, pp. 2673–2681, Nov. 1997, doi: 10.1109/78.650093.
- [13] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proc. 25th ACM SIGKDD Int. Conf. Knowl. Discovery Data Min.*, 2019, pp. 2623–2631.
- [14] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proc. 3rd Int. Conf. Learn. Represent. (ICLR)*, San Diego, CA, USA, 2015, pp. 1–15.
- [15] T. Chai and R. R. Draxler, "Root mean square error (RMSE) or mean absolute error (MAE)?—Arguments against avoiding RMSE in the literature," *Geosci. Model Dev.*, vol. 7, no. 3, pp. 1247–1250, 2014.
- [16] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ, USA: John Wiley & Sons, 2015.
- [17] A. Rosita, "Perbandingan algoritma LSTM dan SVM dalam memprediksi harga aset kripto," *J. Mat. Sains dan Teknol.*, vol. 25, no. 1, pp. 45–56, 2024.